

ETF 시계열 데이터셋 수집 완료 보고

XAI 기반 퇴직연금 포트폴리오 진단 모델 · 백테스팅 유니버스

데이터 버전: v1.0 | 작성일: 2026-05-02 | 수집 기간: 2020-01-02 ~ 2025-04-30

1. 개요

XAI 기반 퇴직연금 포트폴리오 진단 모델의 백테스팅 유니버스 구축을 위해 국내 ETF 전종목의 일별 OHLCV 시계열 데이터를 수집 완료했습니다. **생존편향(Survivorship Bias) 제거**를 핵심 설계 원칙으로, 현재 상장 종목뿐 아니라 수집 기간 내 상장폐지된 종목 데이터도 포함합니다.

2. 데이터셋 기본 정보

수집 기간 2020-01-02 ~ 2025-04-30	총 행 수 653,601행	수집 종목 수 881종	거래일 수 1,311일	종목당 평균 거래일 742일
---	--------------------------	------------------------	------------------------	---------------------------

파일 정보

포맷	크기	경로	용도
Parquet	9.7 MB	raw/price/ohlcvc_all.parquet	분석용 메인 파일 (컬럼형 압축)
CSV	88.2 MB	raw/price/ohlcvc_all.csv	백업 및 검토용

3. 유니버스 구성

수집 대상 현황

구분	종목 수
수집 완료 (현재 상장)	782종
수집 완료 (상장폐지)	99종
수집 완료 합계	881종
미수집 (기간 외 신규상장)	171종
마스터 유니버스 합계	1,052종

기초자산 분류별 분포

기초자산 분류	종목 수
주식	603종
채권	117종
혼합자산	47종
부동산	8종
기타 (TDF, 금리 등)	4종
원자재 (금·은 현물)	3종

* 미수집 171종: 수집 기간(~2025-04-30) 이후 상장된 신규 ETF로 해당 기간 내 거래 데이터 없음. 데이터 오류 아님.

운용사별 분포 (상위 10개)

운용사	종목 수	운용사	종목 수
삼성자산운용	166종	한화자산운용	57종

운용사	종목 수	운용사	종목 수
미래에셋자산운용	161종	신한자산운용	54종
케이비자산운용	94종	키움투자자산운용	40종
한국투자신탁운용	79종	엔에이치아문디자산운용	37종
타임폴리오자산운용	15종	삼성액티브자산운용	11종

4. 컬럼 명세

컬럼명	타입	설명
date	datetime	거래일 (YYYY-MM-DD)
ticker	str	종목코드 (6자리)
name	str	한글종목명
open / high / low / close	float	시가 / 고가 / 저가 / 종가
volume	float	거래량
is_delisted	bool	상장폐지 여부
delist_date	str	상장폐지일 (현재 상장 종목은 NaN)

5. 생존편향 통제 설계

투자 불능 종목 필터링

원본 마스터 유니버스(1,222종)에서 아래 기준으로 170종을 제거하여 1,052종을 최종 유니버스로 확정했습니다.

제거 기준	제거 수	근거
레버리지 / 인버스 (추적배수 ≠ 일반)	106종	퇴직연금 감독규정상 변동성 증폭 파생형 투자 불가
부적격 합성형 (합성 복제 + 비주식·채권 기초자산)	26종	파생상품 위험평가액 비중 40% 초과 우려
선물 추종 전체 (원자재·통화·탄소·국채·주식 선물)	99종	선물 직접 보유 → 파생상품 비중 40% 초과

* 해외 지수 추종 ETF, 커버드콜 ETF 등 퇴직연금 투자 가능 상품은 유니버스에 포함됩니다.

결측치 처리 원칙

구간	처리 방식	이유
상장폐지일 이후	NaN 유지	해당 시점 매매 불가능 → 모델이 인식해야 함
거래 정지 (연속 4일 이하)	직전 영업일 종가 이월 (ffill)	일시적 정지 후 재개 시 연속성 유지
종가 = 0	NaN 처리	데이터 오류로 간주
거래량 = 0	유지	공식 거래 정지일일 수 있음

6. 수집 방법

항목	내용
수집 도구	

항목	내용
	pykrx get_market_ohlcv() (v1.2.7)
수집 방식	종목별 연도 단위 분리 수집 후 병합 (2020~2025년 총 6구간)
요청 간격	1초 sleep (KRX 서버 IP 차단 방지)
중단 재개	raw/price/checkpoint.csv 에 완료 종목 기록, 재실행 시 자동 이어서 수집

7. 검증 결과

검증 항목	결과
날짜 범위 (2020-01-02 ~ 2025-04-30) 정합성	✓ 통과
주요 ETF 전체 기간 데이터 존재 확인 (KODEX200, TIGER200)	✓ 통과
레버리지/인버스 필터 적용 확인 (KODEX인버스 미포함)	✓ 통과
종가 = 0 행 없음 (0건)	✓ 통과
상장폐지일 이후 데이터 NaN 처리 완료	✓ 통과

8. 관련 파일

파일	설명
raw/master_universe.csv	상장 + 상폐 병합 전체 유니버스 (1,222종)
raw/master_filtered.csv	투자 불능 종목 제거 후 최종 목록 (1,052종)
raw/price/ohlcv_all.parquet	일별 OHLCV 메인 파일
raw/price/ohlcv_all.csv	일별 OHLCV CSV 백업
raw/price/failed_tickers.csv	데이터 없는 종목 목록 (171종)
01_build_universe.py	유니버스 구축 및 필터링 스크립트
02_collect_ohlcv.py	OHLCV 수집 스크립트